

Отчет о проделанной работе

Task 1: Greedy decoding

Для `greedy_decode` на LibriSpeech `test-other` получены следующие значения:

Metric	Value	Expected
WER	11.22%	10.4%
CER	3.81%	3.5%
Time	30.54 s	

Task 2: Beam search decoding

Beam search был протестирован для нескольких значений `beam_width`.

Beam width	WER (%)	CER (%)	Time (s)
1	11.24	3.80	35.34
3	11.15	3.78	63.59
10	11.07	3.77	127.86
50	11.10	3.77	696.92

Референсные значения для beam search:

- `WER` $\approx$ 9.9%
- `CER` $\approx$ 3.4%

Лучший результат в моем эксперименте достигается при `beam_width = 10`:

- `WER` = 11.07%
- `CER` = 3.77%


Анализ результатов

Beam search действительно дает небольшое улучшение относительно greedy decoding:

- greedy: `WER` = 11.22%, `CER` = 3.81%;
- beam (`beam_width` = 10): `WER` = 11.07%, `CER` = 3.77%.

Однако это улучшение очень небольшое, тогда как вычислительная стоимость растет быстро:

- переход от `beam_width` = 1 к 3 и 10 чуть улучшает качество;
- переход от 10 к 50 почти не дает выигрыша по качеству;
- при этом время декодирования увеличивается очень сильно.




Task 3: Temperature scaling

Temperature	WER (%)	CER (%)
0.5	11.22	3.81
0.8	11.22	3.81
1.0	11.22	3.81
1.2	11.22	3.81
1.5	11.22	3.81
2.0	11.22	3.81

Анализ результатов

Во всех экспериментах значения **WER** и **CER** остались одинаковыми - temperature scaling меняет распределение вероятностей, но не меняет **argmax** на каждом временном шаге.

Следовательно, на **LibriSpeech test-other** изменение температуры в диапазоне **0.5–2.0** не повлияло на результаты greedy decoding.



Выводы по части 1

- beam search без LM дает только небольшое улучшение качества относительно greedy decoding;
- лучший результат достигается при: **beam_width = 10**;

- дальнейшее увеличение beam width почти не улучшает результат и сильно увеличивает время декодирования;
- temperature scaling не оказал влияния на greedy decoding на LibriSpeech, так как итоговый argmax не меняется.

Task 4: Beam search with shallow fusion

Для shallow fusion с LibriSpeech 3-gram LM был выполнен перебор по параметрам:

- $\alpha \in \{0.01, 0.05, 0.1, 0.5, 1.0, 2.0, 5.0\}$
- $\beta \in \{0.0, 0.5, 1.0, 1.5\}$

Лучший результат был получен при:

- $\alpha = 0.1$
- $\beta = 0.5$
- WER = 11.00%
- CER = 3.75%

Референсное значение:

- WER $\approx$ 9.7%
- CER $\approx$ 3.4%


Анализ

Shallow fusion дает небольшой выигрыш относительно обычного beam search:

- beam: WER = 11.07%, CER = 3.77%
- beam + LM (best): WER = 11.00%, CER = 3.75%

Оптимальный α оказался маленьким, что согласуется с ожидаемым поведением: на in-domain LibriSpeech акустическая модель уже достаточно сильна, поэтому слишком большой вес LM начинает вредить. Это хорошо видно на heatmap: при $\alpha = 2.0$ качество заметно ухудшается, а при $\alpha = 5.0$ деградация качества становится очень сильной.

Task 4: Shallow fusion WER heatmap



Task 5: 4-gram LM

Была проведена оценка с лучшими параметрами из Task 4.

Model	Alpha	Beta	WER (%)	CER (%)
3-gram LM baseline	0.1	0.5	11.00	3.75
4-gram LM	0.1	0.5	11.42	3.82

Анализ

В моем эксперименте 4-gram LM не улучшил качество по сравнению с 3-gram baseline, а наоборот немного ухудшил его. Возможная причина состоит в том, что параметры **alpha** и **beta**, подобранные для 3-gram LM, не являются оптимальными для 4-gram LM. Кроме того, более мощная LM может сильнее доминировать над акустической моделью и приводить к переоценке языковых вероятностей даже при сравнительно малом **alpha**. Еще возможно у меня веса модели как-то коряво скачались.

Task 6: LM rescoring

Для second-pass rescoring был выполнен перебор по той же сетке параметров:

- $\alpha \in \{0.01, 0.05, 0.1, 0.5, 1.0, 2.0, 5.0\}$
- $\beta \in \{0.0, 0.5, 1.0, 1.5\}$

Лучший результат:

- $\alpha = 0.01$
- $\beta = 0.5$
- WER = 10.98%
- CER = 3.74%

Референсные значения:

- WER $\approx$ 9.6%
- CER $\approx$ 3.3%

Анализ


Rescoring оказался немного лучше shallow fusion по WER:

- shallow fusion best: WER = 11.00%
- rescoring best: WER = 10.98%

Разница очень небольшая, но заметно, что rescoring чуть устойчивее. В отличие от shallow fusion, где LM влияет на pruning уже во время поиска, second-pass rescoring сначала сохраняет кандидатов по акустической модели, а затем переупорядочивает их с учетом LM. Поэтому при больших α деградация обычно более плавная.

В моих результатах это видно частично: rescoring на малых α стабилен, но при очень больших α качество все равно ухудшается. Тем не менее лучшая точка у rescoring чуть лучше, чем у shallow fusion.

Task 6: Rescoring WER heatmap



Qualitative examples

Ниже приведены примеры, где хотя бы один LM-based метод изменяет гипотезу относительно обычного beam search.

idx	Reference	Beam	Shallow fusion	Rescoring
24	a fellow who was shut up in prison for life might do it he said but not in a case like this	a fellow who as shut up in prison for life might doit he said but not in a case like this	a fellow who as shut up in prison for life might do it he said but not in a case like this	a fellow who as shut up in prison for life might do it he said but not in a case like this
33	and why did andy call mister gurr father	and why did andy call mister gurfather	and why did andy call mister gur father	and why did andy call mister gur father
79	that's right of course well armed	that's right of course willamed	that's right of course will amed	that's right of course will amed
121	i said a lad bout seventeen in a red cap like yours said gurr very shortly	i said a lad bout seventeen an a red captlic yours said gerevery shortly	i said a lad bout seventeen an a red captlic yours said gerevery shortly	i said a lad bout seventeen and a red captlic yours said gerevery shortly

idx	Reference	Beam	Shallow fusion	Rescoring
153	each that died we washed and shrouded in some of the clothes and linen cast ashore by the tides and after a little the rest of my fellows perished one by one till i had buried the last of the party and abode alone on the island with but a little provision left i who was wont to have so much	each that died we washed and shrowded in some of the clothes and linen cast a shore by the tides and after little the rest of my fellows perished one by one till i had buried the last of the party and aboade alone on the island with but a little provision left i who was wont to have so much	each that died we washed and shrowded in some of the clothes and linen cast a shore by the tides and after a little the rest of my fellows perished one by one till i had buried the last of the party and aboade alone on the island with but a little provision left i who was wont to have so much	each that died we washed and shrowded in some of the clothes and linen cast a shore by the tides and after a little the rest of my fellows perished one by one till i had buried the last of the party and aboade alone on the island with but a little provision left i who was wont to have so much

В этих примерах LM чаще всего помогает вставить пробелы между словами или чуть лучше сегментировать последовательность, хотя полностью исправить ошибки акустической модели он не может.

Task 7: Cross-domain comparison

Я сравнила четыре метода декодинга на двух датасетах: in-domain **LibriSpeech** и out-of-domain **Earnings22**.

Dataset	Method	WER (%)	CER (%)
LibriSpeech	Greedy	11.22	3.81
LibriSpeech	Beam	11.07	3.77
LibriSpeech	Beam + LM	11.00	3.75
LibriSpeech	Rescoring	10.98	3.74
Earnings22	Greedy	54.97	25.58
Earnings22	Beam	54.94	25.38
Earnings22	Beam + LM	55.36	25.43
Earnings22	Rescoring	55.51	25.39

Анализ

Разница между in-domain и out-of-domain качеством очень большая:

- на **LibriSpeech** все методы дают **WER** около **11%**;
- на **Earnings22** **WER** возрастает примерно до **55%**.

Это ожидаемо, потому что акустическая модель обучалась на LibriSpeech и никогда не видела финансовую речь. Поэтому даже дополнительная языковая модель, обученная на LibriSpeech, почти не помогает на Earnings22 и местами даже ухудшает результат. LM хорошо отражает распределение текстов LibriSpeech, но плохо соответствует лексике и стилю earnings calls.



Task 7b: Temperature scaling on Earnings22

Для out-of-domain набора Earnings22 был выполнен перебор:


- $T \in \{0.5, 1.0, 1.5, 2.0\}$

Результаты:

Temperature	Greedy WER (%)	Shallow Fusion WER (%)
0.5	54.97	55.18
1.0	54.97	55.36
1.5	54.97	56.17
2.0	54.97	57.71

Анализ

Для shallow fusion при увеличении температуры качество ухудшается. Повышение T делает акустическое распределение более плоским, из-за чего LM получает больше влияния. На Earnings22 LibriSpeech LM не соответствует домену, поэтому усиление его влияния приводит к деградации, а не к улучшению.



Task 9: Compare LibriSpeech LM vs Financial LM

Сравнение двух языковых моделей:

- LibriSpeech 3-gram
- Financial 3-gram

проводилось для двух методов декодинга:

- shallow fusion (SF)
- rescoreing (RS)

LibriSpeech

LM	Method	WER (%)	CER (%)
LibriSpeech 3-gram	SF	11.00	3.75
LibriSpeech 3-gram	RS	11.02	3.75
Financial 3-gram	SF	10.93	3.75
Financial 3-gram	RS	11.00	3.75

Earnings22

LM	Method	WER (%)	CER (%)
LibriSpeech 3-gram	SF	55.36	25.43
LibriSpeech 3-gram	RS	55.06	25.41
Financial 3-gram	SF	52.47	25.00

LM	Method	WER (%)	CER (%)
Financial 3-gram	RS	54.82	25.38

Анализ

На **LibriSpeech** различия между LM очень малы. Это ожидаемо: сам датасет уже является in-domain, а акустическая модель и стандартная LibriSpeech LM хорошо соответствуют условиям задачи.

Интересно, что financial LM в shallow fusion показывает даже слегка лучший **WER**.


На **Earnings22** financial LM уже дает заметно лучшие результаты. Лучший результат получается у:

- financial 3-gram + shallow fusion
- WER = 52.47%

Это лучше, чем:

- librispeech 3-gram + shallow fusion (55.36%)
- librispeech 3-gram + rescoring (55.06%)

Таким образом, domain-specific LM действительно помогает на out-of-domain речи, особенно в shallow fusion. При этом financial LM в rescoring не дал столь же сильного улучшения, как в shallow fusion, что может быть связано с ограниченной мощностью кандидатов, приходящих из первого beam-search pass.



Выводы по части 2

- shallow fusion дает небольшой выигрыш на LibriSpeech, но очень чувствителен к слишком большим α ;
- 4-gram LM в моем эксперименте не улучшил результат относительно 3-gram baseline;
- rescoring показал лучший итоговый WER среди LM-based методов на LibriSpeech, хотя преимущество очень небольшое;
- на Earnings22 LibriSpeech LM почти не помогает и иногда ухудшает качество;
- повышение температуры на Earnings22 усиливает влияние несоответствия между акустической моделью и неподходящей LM, поэтому shallow fusion деградирует;
- financial-domain LM действительно полезен на Earnings22 и дает лучший результат в Task 9.